

A) "El banco aguanta"

$$1) X = \begin{bmatrix} 0 & 0 & 0 & 1 \\ 1 & 1 & 0 & 1 \\ 1 & 0 & 1 & 2 \end{bmatrix} = E + P$$

construcción del significado de la palabra con E + el contexto de la posición de cada token con P

2) Proyecciones

$$Q = X \cdot W_Q = \begin{bmatrix} 0 & 0 & 0 & 1 \\ 1 & 1 & 0 & 1 \\ 1 & 0 & 1 & 2 \end{bmatrix} \cdot \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix} = \begin{bmatrix} 0 & 0 & 0 & 1 \\ 1 & 1 & 0 & 1 \\ 1 & 0 & 1 & 2 \end{bmatrix} = X$$

Q : qué información busca el token

$$K = X \cdot W_K = \begin{bmatrix} 0 & 0 & 0 & 1 \\ 1 & 1 & 0 & 1 \\ 1 & 0 & 1 & 2 \end{bmatrix} \cdot \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 1 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 \end{bmatrix} = \begin{bmatrix} 0 & 0 & 0 & 0 \\ 1 & 1 & 0 & 0 \\ 2 & 1 & 0 & 0 \end{bmatrix}$$

K : qué inf. ofrece para que otros tokens lo encuentren

$$V = X \cdot W_V = \begin{bmatrix} 0 & 0 & 0 & 1 \\ 1 & 1 & 0 & 1 \\ 1 & 0 & 1 & 2 \end{bmatrix} \cdot I = \begin{bmatrix} 0 & 0 & 0 & 1 \\ 1 & 1 & 0 & 1 \\ 1 & 0 & 1 & 2 \end{bmatrix} = X$$

3) Afinidades

$$S = Q \cdot K^T = \begin{bmatrix} 0 & 0 & 0 & 1 \\ 1 & 1 & 0 & 1 \\ 1 & 0 & 1 & 2 \end{bmatrix} \cdot \begin{bmatrix} 0 & 1 & 2 \\ 0 & 1 & 1 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{bmatrix} = \begin{bmatrix} 0 & 0 & 0 \\ 0 & 2 & 3 \\ 0 & 1 & 2 \end{bmatrix}$$

V : qué contenido entrega si lo eligen.

Mide cuánto le "importa" cada token a otro.

4) Escala

$$S / \sqrt{4} = \begin{bmatrix} 0 & 0 & 0 \\ 0 & 1 & 3/2 \\ 0 & 1/2 & 1 \end{bmatrix}$$

Busca normalizar la varianza a 1 para que softmax no se sature y anule el gradiente.

5) Máscara causal

$$S = \begin{bmatrix} 0 & -\infty & -\infty \\ 0 & 1 & -\infty \\ 0 & 1/2 & 1 \end{bmatrix} \quad e^{-\infty} = 0 \text{ deja al peso anulado.}$$

6) Matriz de atención

$$A = \text{softmax}(S) = \begin{bmatrix} 1.000 & 0.000 & 0.000 \\ 0.269 & 0.731 & 0.000 \\ 0.186 & 0.307 & 0.506 \end{bmatrix}$$

Convierte pentafos de cada fila a una distribución.

7) Mezcla

$$A \cdot V = \begin{bmatrix} 0.000 & 0.000 & 0.000 & 1.000 \\ 0.731 & 0.731 & 0.000 & 1.000 \\ 0.813 & 0.307 & 0.506 & 1.505 \end{bmatrix}$$

Reescribe cada Token como la mezcla de sus valores, ponderados por la atención.

W_0 proyecta la mezcla al espacio del modelo.

$$(A \cdot V) \cdot W_0 = (A \cdot V) \cdot I = A \cdot V$$

8) Residual

$$Z = X + (A \cdot V) \cdot W_0 = \begin{bmatrix} 0 & 0 & 0 & Z \\ 1.731 & 1.731 & 0 & Z \\ 1.813 & 0.307 & 1.506 & 3.505 \end{bmatrix}$$

suma la conexión de la atención o la entrada.

9) Layer Normalization: se normaliza cada fila a media 0 y varianza 1 para que la escala no crezca entre capas.

$$F_1: \mu_1 = \frac{2}{4} = 0.5 = \sum_{i=1}^4 \frac{X_i}{4}$$

$$\sigma_1^2 = \sum_{i=1}^4 \frac{(X_i - \mu_1)^2}{4} = 0.75$$

$$\frac{X_i - \mu}{\sigma} \sim N(0, 1)$$

$$F_2: \mu_2 = \sum_{i=1}^4 \frac{X_i}{4} = 1.366$$

$$\sigma_2^2 = \sum_{i=1}^4 \frac{(X_i - \mu_2)^2}{4} = 0.634$$

$$LN(Z) = \begin{bmatrix} -0.577 & -0.577 & -0.577 & 1.732 \\ 0.459 & 0.459 & -1.715 & 0.797 \\ 0.026 & -1.292 & -0.242 & 1.507 \end{bmatrix}$$

$$F_3: \mu_3 = \sum_{i=1}^4 \frac{X_i}{4} = 1.783$$

$$\sigma_3^2 = \sum_{i=1}^4 \frac{(X_i - \mu_3)^2}{4} = 1.305$$

10) Feed-Forward: procesa cada token por separado con ReLU. Obtiene algo nuevo a partir de la mezcla lineal de la atención. (2)

$$LN(z) \cdot W_1 = \begin{bmatrix} 0 & 1.154 & 0 & 0 \\ 0 & -0.918 & 0 & 0 \\ 1.318 & 1.266 & 0 & 0 \end{bmatrix} = \begin{bmatrix} 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 1.318 & -1.318 & 0 & 0 \end{bmatrix}$$

$$ReLU(LN(z) \cdot W_1) = \begin{bmatrix} 0 & 1.154 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 1.318 & 1.266 & 0 & 0 \end{bmatrix} = \begin{bmatrix} 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 1.318 & 0 & 0 & 0 \end{bmatrix}$$

$$ReLU \cdot W_2 = ReLU(LN(z) \cdot W_1) \cdot I = ReLU(LN(z) \cdot W_1) = FFN$$

11) Residual: suma la conexión de la feed-forward al residual stream y conserva la información anterior y el camino del gradiente.

$$H = Z + FFN = \begin{bmatrix} 0 & 0 & 0 & 2 \\ 1.731 & 1.731 & 0 & 2 \\ 3.131 & 0.307 & 1.506 & 3.505 \end{bmatrix}$$

12) LN final: pasa el vector a una escala estable antes de pasar a logits. Repitiendo el procedimiento hecho en 9),

$$LN(H) = \begin{bmatrix} -0.577 & 0.577 & -0.577 & 1.732 \\ 0.459 & 0.459 & -1.715 & 0.797 \\ 0.793 & -1.405 & -0.472 & 1.084 \end{bmatrix} \begin{matrix} \downarrow \text{No cambian respecto} \\ \times \text{ al paso 9).} \end{matrix}$$

13) Predicción: se compara la última fila con cada palabra del vocabulario y softmax convierte los puntajes a una distribución de probabilidad sobre el siguiente token.

Se toma la última fila de los ^{logits} ~~logits~~: $[0.793, -1.405, -0.472, 1.084]$

$$\text{logits} = [0.793, -1.405, -0.472, 1.084] \cdot \begin{bmatrix} 0 & 0 & 0 & 0 & 2 & 0 \\ 0 & 0 & 0 & 0 & 0 & 2 \\ 0 & 0 & 1 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ -0.472 \\ -0.472 \\ 1.586 \\ -2.810 \end{bmatrix}$$

Aplicando Softmax,

$$e^0 = 1$$

$$e^{-0.472} = 0.624$$

$$e^{1.586} = 4.884$$

$$e^{-2.810} = 0.060$$

Distribución:

Palabra	El	banco	aguantó	presta	peso	dinero
-	0.122	0.122	0.076	0.076	0.596	0.007

El modelo predice "peso" con probabilidad 0.596

"El banco presta". Segunda frase del punto A. Como la primera frase ya fue calculada, las justificaciones de los cálculos son onológicas ya que sólo se modifican los números concretos de los matrices.

1) Entrada

$$X = E + P = \begin{bmatrix} 0 & 0 & 0 & 1 \\ 1 & 1 & 0 & 0 \\ 0 & 1 & 1 & 0 \end{bmatrix} + \begin{bmatrix} 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 2 \end{bmatrix} = \begin{bmatrix} 0 & 0 & 0 & 1 \\ 1 & 1 & 0 & 1 \\ 0 & 1 & 1 & 2 \end{bmatrix}$$

2) Proyecciones

Se sabe del ejemplo anterior que los matrices Q y V pueden iguales a X debido a que sus pesos son la matriz identidad.

$$K = X \cdot W_k = \begin{bmatrix} 0 & 0 & 0 & 1 \\ 1 & 1 & 0 & 1 \\ 0 & 1 & 1 & 2 \end{bmatrix} \cdot \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 1 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 \end{bmatrix} = \begin{bmatrix} 0 & 0 & 0 & 0 \\ 1 & 1 & 0 & 0 \\ 0 & 2 & 0 & 0 \end{bmatrix}$$

3) Afinidades

$$S = Q \cdot K^T = \begin{bmatrix} 0 & 0 & 0 & 1 \\ 1 & 1 & 0 & 1 \\ 0 & 1 & 1 & 2 \end{bmatrix} \cdot \begin{bmatrix} 0 & 1 & 0 \\ 0 & 1 & 2 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{bmatrix} = \begin{bmatrix} 0 & 0 & 0 \\ 0 & 2 & 2 \\ 0 & 1 & 2 \end{bmatrix}$$

4) Escala: $S/\sqrt{4}$

$$S = \begin{bmatrix} 0 & 0 & 0 \\ 0 & 1 & 1 \\ 0 & 1/2 & 1 \end{bmatrix}$$

5) Máscara causal

$$S = \begin{bmatrix} 0 & -\infty & -\infty \\ 0 & 1 & -\infty \\ 0 & 1/2 & 1 \end{bmatrix}$$

6) Matriz de atención: $A = \text{softmax}(S)$

$$F_1: e^0 = 1, e^{-\infty} = 0$$

$$F_2: e^0 = 1, e^1 = e \approx 2.718, e^{-\infty} = 0$$

$$F_3: e^0 = 1, e^{1/2} = 1.649, e^1 = 2.718$$

$$\left. \begin{array}{l} F_1: e^0 = 1, e^{-\infty} = 0 \\ F_2: e^0 = 1, e^1 = e \approx 2.718, e^{-\infty} = 0 \\ F_3: e^0 = 1, e^{1/2} = 1.649, e^1 = 2.718 \end{array} \right\} A = \begin{bmatrix} 1 & 0 & 0 \\ 0.269 & 0.731 & 0 \\ 0.186 & 0.307 & 0.506 \end{bmatrix}$$

(MISMA MATRIZ)

7) Mezcla

$$A \cdot V = \begin{bmatrix} 1 & 0 & 0 \\ 0.269 & 0.731 & 0 \\ 0.186 & 0.307 & 0.506 \end{bmatrix} \cdot \begin{bmatrix} 0 & 0 & 0 & 1 \\ 1 & 1 & 0 & 1 \\ 0 & 1 & 1 & 2 \end{bmatrix} = \begin{bmatrix} 0 & 0 & 0 & 1 \\ 0.731 & 0.731 & 0 & 1 \\ 0.307 & 0.813 & 0.506 & 1.505 \end{bmatrix}$$

$$(A \cdot V) \cdot W_b = (A \cdot V) \cdot I = (A \cdot V)$$

8) Residual: $X + (A \cdot V) \cdot W_b$

$$Z = \begin{bmatrix} 0 & 0 & 0 & 1 \\ 1 & 1 & 0 & 1 \\ 0 & 1 & 1 & 2 \end{bmatrix} + \begin{bmatrix} 0 & 0 & 0 & 1 \\ 0.731 & 0.731 & 0 & 1 \\ 0.307 & 0.813 & 0.506 & 1.505 \end{bmatrix} = \begin{bmatrix} 0 & 0 & 0 & 2 \\ 1.731 & 1.731 & 0 & 2 \\ 0.307 & 1.813 & 1.506 & 3.505 \end{bmatrix}$$

9) Layer Normalization:

$LN(Z) = \frac{X_i - \mu}{\sigma}$ $\forall i$ dentro de los 3 filas. F_1 y F_2 son iguales de ejemplo previo.

$$LN(Z) = \begin{bmatrix} -0.577 & -0.577 & -0.577 & 1.732 \\ 0.459 & 0.459 & -1.715 & 0.797 \\ -1.292 & 0.026 & -0.242 & 1.507 \end{bmatrix} \text{ Idéntica de ejemplo anterior, con } a_{31} \text{ y } a_{32} \text{ invertidos.}$$

10) Feed-Forward:

$$LN(Z) \cdot W_1 = \begin{bmatrix} 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 1.318 & 1.318 & 0 & 0 \end{bmatrix} \rightarrow \text{Aplicar ReLU sólo hace cero a } a_{31}.$$

~~ReLU~~

$$FFN = ReLU \cdot W_2 = \begin{bmatrix} 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 1.318 & 0 & 0 \end{bmatrix} \cdot I = \begin{bmatrix} 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 1.318 & 0 & 0 \end{bmatrix}$$

11) Residual

$$H = Z + FFN = \begin{bmatrix} 0 & 0 & 0 & 2 \\ 1.731 & 1.731 & 0 & 2 \\ 0.307 & 3.131 & 1.506 & 3.505 \end{bmatrix}$$

12) LN final: Muy similar al LN de ejemplo anterior, variando sólo a_{31} y a_{32}

$$LN(H) = \begin{bmatrix} -0.577 & -0.577 & -0.577 & 1.732 \\ 0.459 & 0.459 & -1.715 & 0.797 \\ -1.405 & 0.793 & -0.472 & 1.084 \end{bmatrix}$$

13) Predicción:

$$\text{logits} = [1.405, 0.793, -0.472, 1.084] \cdot W_{out}$$

$$= [0, 0, -0.472, -0.472, -2.840, 1.586]$$

Se intercambiaron los valores de los logits de "peso" y "dinero" respecto al caso anterior. Por lo tanto, el modelo predice "dinero" con probabilidad 0.596.

PARTE B

"El banco aguanta"

5) No se reemplaza por $-\infty$, se usa la matriz de 4)

6) $A = \text{softmax}(S)$, donde $S = \begin{bmatrix} 0 & 0 & 0 \\ 0 & 1 & 3/2 \\ 0 & 1/2 & 1 \end{bmatrix}$

$$e^0 = 1, e^1 = 2.718, e^{0.5} = 1.649, e^{1.5} = 4.482.$$

$$A = \begin{bmatrix} 0.333 & 0.333 & 0.333 \\ 0.122 & 0.331 & 0.547 \\ 0.186 & 0.307 & 0.506 \end{bmatrix}$$

7) Mezcla:

$$A \cdot V = \begin{bmatrix} 0.666 & 0.333 & 0.333 & 1.332 \\ 0.878 & 0.331 & 0.547 & 1.547 \\ 0.813 & 0.307 & 0.506 & 1.505 \end{bmatrix}$$

$$(A \cdot V) \cdot W_0 = (A \cdot V) \cdot I = A \cdot V$$

8) Residual

$$Z = X + (A \cdot V) W_0 = \begin{bmatrix} 0.666 & 0.333 & 0.333 & 2.332 \\ 1.878 & 1.331 & 0.547 & 2.547 \\ 1.813 & 0.307 & 1.506 & 3.505 \end{bmatrix}$$

9) LN(Z): Aplicando el método previamente utilizado

$$LN(Z) = \begin{bmatrix} -0.302 & -0.703 & -0.703 & 1.709 \\ 0.412 & -0.334 & -1.402 & 1.324 \\ 0.026 & -1.292 & -0.242 & 1.507 \end{bmatrix}$$

La fila de banco es: $[0.412, -0.334, -1.402, 1.324]$

"El banco presta"

$$4) S = \begin{bmatrix} 0 & 0 & 0 \\ 0 & 1 & \frac{1}{2} \\ 0 & \frac{1}{2} & 1 \end{bmatrix} \rightarrow \text{escalado por factor } \frac{1}{\sqrt{4}}$$

6) Atención

$A = \text{softmax}(S)$. Repitiendo el método,

$$A = \begin{bmatrix} 0.333 & 0.333 & 0.333 \\ 0.122 & 0.331 & 0.547 \\ 0.186 & 0.307 & 0.506 \end{bmatrix}$$

7) Mezcla.

$$A \cdot V = \begin{bmatrix} 0.333 & 0.666 & 0.333 & 1.332 \\ 0.331 & 0.878 & 0.547 & 1.547 \\ 0.307 & 0.813 & 0.506 & 1.505 \end{bmatrix}$$

$$(A \cdot V) \cdot W_0 = (A \cdot V) \cdot I = A \cdot V$$

8) Residual

(3)

$$Z = X + (A \cdot V) \cdot W_b = \begin{bmatrix} 0.333 & 0.666 & 0.333 & 2.332 \\ 1.331 & 1.878 & 0.547 & 2.547 \\ 0.307 & 1.813 & 1.506 & 3.505 \end{bmatrix}$$

9) LN(Z) : Aplicando normalización a cada fila,

$$LN(Z) = \begin{bmatrix} -0.703 & -0.302 & -0.703 & 1.709 \\ -0.334 & 0.412 & -1.402 & 1.324 \\ -1.292 & 0.026 & -0.242 & 1.507 \end{bmatrix}$$

La fila de banco es: $[-0.334, 0.412, -1.402, 1.324]$

PREGUNTAS

- 1) En la parte A, la fila de "banco" es igual para ambos frees. Con la máscara, "banco" solo ve a "El" y a sí mismo, que son iguales en los frees. En B sí cambia: los embeddings en d_1 y d_2 están invertidos. Sin máscara, "banco" da atención al verbo siguiente y recibe su información.
- 2) La predicción no proviene de la fila de "banco" sino de la última fila, que por la máscara es la única que ve toda la frase. "aguarda" aporta " d_1 " y "presta" aporta " d_2 ". Luego W_1 contrasta ' d_1 ' con ' d_2 ', ReLU se queda con el lado ganador y 'Wout' lo traduce a pesos.
- 3) Son iguales. La máscara solo bloquea los tokens posteriores y la última fila no tiene, por lo que su fila de atención y su LN(Z) son iguales con o sin máscara. La máscara solo afecta las representaciones de tokens anteriores.

4) La parte A se parece a un decoder-only como GPT, que tiene máscara causal y se entrena prediciendo el token siguiente. Se usa para la generación de texto.

La parte B se parece a un encoder-only como BERT, que produce una representación contextual por token. Se usa para clasificar y generar embeddings.

5) En este ejercicio, S y A no cambian. 'P' sólo trata d_4 y W_4 anula d_4 en la matriz K , por lo que los productos punto son iguales. Lo que cambia es $V = X$, que pierde la componente de posición en d_4 . En consecuencia, se ven afectadas Z , LN y las probabilidades finales debido a que 'What' no observa d_4 , aunque ~~las palabras~~ ^{el token} predicho sea el mismo.

En una frase donde ~~cambia~~ el orden cambia el sentido, sin 'P' la atención trata a los tokens como un conjunto, ~~donde permutar~~ ^{donde permutar} las palabras sólo permuta la salida y el modelo no puede distinguir quién hace qué.

En B, el encoder sería con análogo a tener un Bag of Words; y en A la máscara ayuda pero es mucho más difícil por tener 'P'.